

Funções

- Variável independente/dependente


Dependente ou de resposta: é o dado mensurado no trabalho, representa uma grandeza com o valor dependente de como a variável independente é manipulada.

Independente ou de agrupamento: representa uma grandeza que está sendo manipulada em um experimento.

- Coeficiente Angular

Permite a compreensão da taxa de variação média de uma variável dependente em relação à variável independente.

Exemplo



mês	Publicidade	Vendas
1.	1.000	10.500
2.	2.000	12.000
3.	3.000	13.500
4.	4.000	15.000
5.	5.000	16.500

Representação da relação:

y = vendas

x = investimento em publicidade

a = c. linear (intercepto)

b = c. angular

$$y = a + bx$$

$$b = \frac{\Delta y}{\Delta x} \Rightarrow$$

$$b = \frac{16.500 - 10.500}{5.000 - 1.000} \Rightarrow$$

$$b = \frac{6.000}{4.000} \Rightarrow b = 1,5$$

"A cada R\$ 1.000 adicionais em publicidade, as vendas aumentam cerca de R\$ 1.500."

- Intercepto

Serve para identificar o valor de uma variável dependente quando a variável independente está zerada.

Representação da relação:

y = vendas

x = investimento em publicidade


a = c. linear (intercepto)

b = c. angular

$$y = a + bx$$

Com base no exemplo anterior

$$y = 9.000 + 1,5x \Rightarrow a = 9000$$



Estatística descritiva

- **Variância** indica o quanto os dados estão afastados da média

exemplo: [6, 7, 7, 7, 8] média = 7

Nota	Distância da média	Distância ²
6	-1	1
7	0	0
7	0	0
8	+1	1
7	0	0

Variância = média dos quadrados dos desvios em relação à média

$s^2 \rightarrow$ variância amostral

$\sigma^2 \rightarrow$ variância populacional

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

$$\sigma^2 = \frac{\sum (x - \bar{x})^2}{N}$$

$x \rightarrow$ cada valor da população

$\bar{x} \rightarrow$ média da população

$N \rightarrow$ número total de elementos

$\sum \rightarrow$ soma de todos os valores calculados

a variância é expressa em unidades ao quadrado, por isso muitas vezes se utiliza o **desvio padrão**, que é a raiz quadrada da variância, para facilitar a interpretação.

11

Exercício

$m \rightarrow$ média dos produtos

$\mu \rightarrow$ Distância

$\mu_1 \rightarrow$ lista das distâncias

$\sigma^2 \rightarrow$ variância populacional

$N \rightarrow$ Número de Observações

$\sigma \rightarrow$ Desvio Padrão

$$m = \frac{70}{6} \Rightarrow m \approx 11,666$$

$$\mu_1 = [\mu_1, \mu_2, \mu_3, \mu_4, \mu_5, \mu_6] \Rightarrow$$

$$\mu_1 = [-1,666; 0,333; -3,666; 3,333; -0,666; 2,333]$$

Vendas	μ	μ^2
10	-1,666	2,775
12	0,333	0,111
8	-3,666	13,439
15	3,333	11,115
11	-0,666	0,443
14	2,333	5,447

$$m = 11,666$$

$$\text{Soma} = 33,33$$

$$\sigma^2 = \frac{\sum (m - \mu)^2}{N} \Rightarrow$$

$$\sigma^2 = \frac{33,33}{6} \Rightarrow \sigma^2 = 5,555$$

$$\sigma = \sqrt{\sigma^2} \Rightarrow \sigma = \sqrt{5,555} \Rightarrow$$

$$\sigma = 2,356$$

Covariância e Correlação

Covariância: mede o grau de associação entre duas variáveis.

Positiva: quando uma variável aumenta a outra tende a aumentar também.

Negativa: quando uma variável aumenta a outra tende a diminuir.

Próxima de zero: indica pouca ou nenhuma relação linear.

O valor depende da escala das variáveis, o que dificulta comparações diretas.

Correlação: é uma medida padronizada da covariância, que varia entre -1 e $+1$.

$+1$ indica correlação perfeita positiva

-1 indica correlação perfeita negativa

0 indica ausência de relação linear

Por ser padronizada, permite comparar relações entre variáveis diferentes, independentemente da escala.

//

Uma empresa registrou horas de estudo e nota obtida em uma prova.

Aluno	Horas estudadas (X)	Nota (Y)
A	2	5
B	4	6
C	6	8
D	8	9

Calcular a covariância populacional

1. Calcular a média de x
2. Calcular a média de y

$\bar{x}$ = média de x

$\bar{y}$ = média de y

x	y	$x - \bar{x}$	$y - \bar{y}$	$(x - \bar{x}) \cdot (y - \bar{y})$
2	5	-3	-2	6
4	6	-1	-1	1
6	8	1	1	1
8	9	3	2	6
				14

$$\bar{x} = 5$$

$$\bar{y} = 7$$

$$Cov = \frac{14}{4} \Rightarrow Cov = 3,5$$

//

Considere dois conjuntos de dados:

Conjunto A

X	Y
1	10
2	20
3	30
4	40
5	50

Conjunto B

X	Y
1	1000
2	2000
3	3000
4	4000
5	5000

1. Em qual conjunto a relação linear parece mais forte?

R: em ambos.

2. Qual conjunto terá a maior covariância?

R: conjunto B.

3. A correlação dos dois conjuntos será igual ou diferente?

R: igual.

4. O que isso mostra sobre a principal diferença entre correlação e covariância?

R: a covariância depende da escala, podendo inflar o resultado, enquanto a correlação trabalha de uma forma mais neutra por não depender de escalas.

//

Regressão Linear

A regressão linear é um método estatístico que gera uma fórmula baseada em variáveis, coeficientes e erros, e que pode ser avaliada por métricas como R^2 .

Principais elementos:

1- Variável dependente (y)

• É o que queremos prever ou explicar

2- Variável independente (x)

• É o fator explicativo ou preditor

3- Coeficiente angular (b ou β_1)

• Representa a inclinação da reta

4- Intercepto (α ou β_0)

- Valor de Y quando $x=0$

5- Erro ou Resíduo (ϵ)

- Diferença entre o valor observado e o valor previsto
- Mostra o quanto o modelo não consegue explicar

6- Equação do modelo

- Forma geral:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- Em regressão múltipla:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

//

Cenário

Uma escola registrou quantas horas cada aluno estudou para uma prova e a nota obtida.

Aluno	Horas estudadas (X)	Nota (Y)
A	1	4
B	2	5
C	3	7
D	4	8
E	5	11

Etapa 1: calcular as médias dos valores

$$\bar{x} = 3$$

$$\bar{y} = 7$$

Etapa 2: montar a tabela auxiliar

x	y	$x - \bar{x}$	$y - \bar{y}$	$(x - \bar{x})^2$	$(x - \bar{x})(y - \bar{y})$
1	4	-2	-3	4	6
2	5	-1	-2	1	2
3	7	0	0	0	0
4	8	1	1	1	1
5	11	2	4	4	8
				10	

Etapa 3: calcular a variância de x

$$\text{var}(x) = \frac{\sum (x - \bar{x})^2}{N} \Rightarrow \text{var}(x) = \frac{10}{5} \Rightarrow \text{var}(x) = 2$$

Etapa 4: calcular a covariância

$$\text{cov}(x, y) = \frac{\sum (x - \bar{x})(y - \bar{y})}{N} \Rightarrow \text{cov}(x, y) = \frac{17}{5} \Rightarrow \text{cov}(x, y) = 3,4$$

Etapa 5: calcular o coeficiente angular

$$b_1 = \frac{\text{cov}(x, y)}{\text{var}(x)} \Rightarrow b_1 = \frac{3,4}{2} \Rightarrow b_1 = 1,7$$

"Cada hora adicional de estudo aumenta a nota em 1,7 pontos."

Etapa 6: calcular o intercepto

$$b_0 = \bar{y} - b_1 \bar{x} \Rightarrow b_0 = 7 - 1,7 \cdot 3 \Rightarrow b_0 = 1,9$$

Etapa 7: montar a reta da regressão

$$\hat{y} = b_0 + b_1 x \Rightarrow \hat{y} = 1,9 + 1,7 \cdot x$$

Etapa 8: Prevendo

Aluno que estudou 6h $\rightarrow$

$$\hat{y}(6) = 1,9 + 1,7 \cdot 6 \Rightarrow \hat{y}(6) = 12,1$$

Aluno que estudou 8h $\rightarrow$

$$\hat{y}(8) = 1,9 + 1,7 \cdot 8 \Rightarrow \hat{y}(8) = 15,5$$

1/